

Lab02__padovani

Rafael Padovani da Cruz

Laboratório 02

Processamento de Bases de Dados em Lote

```
library(tidyverse)
```

Warning: pacote 'tidyverse' foi compilado no R versão 4.6.1

Warning: pacote 'tidyr' foi compilado no R versão 4.6.1

Warning: pacote 'readr' foi compilado no R versão 4.6.1

Warning: pacote 'purrr' foi compilado no R versão 4.6.1

Warning: pacote 'forcats' foi compilado no R versão 4.6.1

Warning: pacote 'lubridate' foi compilado no R versão 4.6.1

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
```

```
v dplyr      1.2.1      v readr      2.2.0
```

```
v forcats   1.0.1      v stringr    1.6.0
```

```
v ggplot2    4.0.3      v tibble     3.3.1
```

```
v lubridate  1.9.5      v tidyr      1.3.2
```

```
v purrr      1.2.2
```

```
-- Conflicts ----- tidyverse_conflicts() --
```

```
x dplyr::filter() masks stats::filter()
```

```
x dplyr::lag()     masks stats::lag()
```

```
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(ggplot2)
library(ggcal)
```

1 - Quais são as estatísticas suficientes para a determinação do percentual de vôos atrasados na chegada (ARRIVAL_DELAY > 10)?

As estatísticas suficientes são: a contagem de voos totais e a contagem de voos atrasados por cia, ela serão utilizadas para calcularmos o percentual de voos atrasados de cada companhia.

2 - Crie uma função chamada getStats

```
getStats <- function(input, pos) {
  input %>%
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%
    drop_na(YEAR, MONTH, DAY, AIRLINE, DEPARTURE_DELAY) %>%
    group_by(MONTH, DAY, AIRLINE) %>%
    summarise(
      TOTAL_FLIGHTS = n(),
      TOTAL_DELAYED = sum(DEPARTURE_DELAY > 10),
      .groups = "drop"
    )
}
```

3 - Importar o arquivo flights.csv.

```
cols <- cols_only(
  YEAR = col_integer(),
  MONTH = col_integer(),
  DAY = col_integer(),
  AIRLINE = col_character(),
  DEPARTURE_DELAY = col_double()
)

df <- read_csv_chunked(
  file = "flights.csv",
  callback = DataframeCallback$new(getStats),
  chunk_size = 100000,
  col_types = cols
)
```


4 - Crie uma função chamada computeStats

```
computeStats <- function(df) {  
  df %>%  
    group_by(MONTH, DAY, AIRLINE) %>%  
    summarise(  
      SUM_FLIGHTS = sum(TOTAL_FLIGHTS),  
      SUM_DELAYED = sum(TOTAL_DELAYED),  
      .groups = "drop"  
    ) %>%  
    mutate(  
      Cia = AIRLINE,  
      Data = as.Date(paste("2015", MONTH, DAY, sep = "-")),  
      Perc = SUM_DELAYED / SUM_FLIGHTS  
    ) %>%  
    select(Cia, Data, Perc)  
}  
  
final_stats <- computeStats(df)
```

5 - Produza um mapa de calor em formato de calendário para cada Cia. Aérea.


```
pal <- scale_fill_gradient(low = "#4575b4", high = "#d73027")  
  
baseCalendar <- function(stats, airline) {  
  sub_stats <- stats %>% filter(Cia == airline)  
  calendar_plot <- ggcal(sub_stats$Data, sub_stats$Perc)  
  
  return(calendar_plot)  
}  
  
cAA <- baseCalendar(final_stats, "AA")  
cDL <- baseCalendar(final_stats, "DL")  
cUA <- baseCalendar(final_stats, "UA")  
cUS <- baseCalendar(final_stats, "US")  
  
cAA + pal + ggtitle("Percentual de Atrasos - American Airlines (AA)")
```

Percentual de Atrasos – American Airlines (AA)




```
cDL + pal + ggtitle("Percentual de Atrasos – Delta Air Lines (DL)")
```

Percentual de Atrasos – Delta Air Lines (DL)




```
cUA + pal + ggtitle("Percentual de Atrasos - United Airlines (UA)")
```

Percentual de Atrasos – United Airlines (UA)



```
cUS + pal + ggtitle("Percentual de Atrasos - US Airways (US)")
```

Percentual de Atrasos – US Airways (US)



```
Sys.setenv(TZ = "America/Sao_Paulo")  
Sys.time()
```

```
[1] "2026-08-25 00:09:18 -03"
```